

Tema 1 — Introducción a la IA Agéntica: Fundamentos, Impulsores y Riesgos

Índice del Tema 1

- 1.1 IA Agéntica: sistemas autónomos que actúan, no solo generan
- 1.2 Bucle central: percibir → pensar → actuar
- 1.3 Tres niveles de autonomía: tradicional, generativa, agéntica
- 1.4 Impulsores técnicos detrás del auge de la IA Agéntica
- 1.5 Los nuevos poderes de la IA Agéntica exigen seguridad especializada
- 1.6 Conclusión: autonomía y orientación a objetivos definen a la IA Agéntica

1.1 IA Agéntica: sistemas autónomos que actúan, no solo generan

- Clase de sistemas de IA autónomos y orientados a objetivos: deciden y actúan sin supervisión constante
- Combinan cognición avanzada con control activo — razonan, planifican, mantienen memoria, usan herramientas
- Monitorean el entorno o las solicitudes del usuario y descomponen un objetivo en subobjetivos
- Secuencian acciones y **adaptan dinámicamente su estrategia** a medida que cambian las condiciones
- La industria la describe como la "próxima ola" de IA: más un compañero de equipo digital que un asistente pasivo
- También llamada "**AI with agency**" — actúa con agencia propia, no solo responde prompts

1.1 La industria coincide: decisión y ejecución autónoma

- **IBM (2025):** los sistemas agénticos persiguen objetivos complejos con supervisión limitada, y planifican y ejecutan de forma autónoma
- **Anthropic (2024):** un agente *"opera de forma independiente durante períodos extendidos, usando herramientas para cumplir tareas complejas"*
- Otros grupos: cualquier sistema capaz de *"tomar decisiones y actuar de forma autónoma"* hacia un objetivo
- Ejemplos tempranos: autos autónomos, asistentes personales agendando reuniones, copilotos de investigación multi-paso
- En la práctica: un LLM genera un plan y módulos/herramientas ejecutan cada paso, mientras la IA evalúa e itera
- Andrew Ng y otros: la IA Agéntica será foco tecnológico central — la IA como solucionador de problemas autónomo

Fig. 1.1 — Mapa mental de alto nivel de la IA Agéntica



Fig. 1.1 — Mapa mental de alto nivel de la IA Agéntica

1.2 Bucle central: percibir → pensar → actuar

- Arquitectura compleja construida a partir de componentes que colaboran en un **bucle iterativo percibir-pensar-actuar** (*sense-think-act*)
- Percibe una entrada (usuario o entorno) → razonamiento/planificación genera una estrategia → acción/herramientas ejecutan
- La **Seven-Layer AI Agent Architecture** (Huang & Huang, 2025) ofrece un marco detallado de estos componentes
- Xi et al. (2025): la survey académica "*The Rise and Potential of LLM-Based Agents*" propone un framework equivalente de **brain–perception–action**, ampliamente citado en la literatura de agentes basados en LLM
- La Fig. 1.2, en la próxima slide, ilustra este bucle de alto nivel

Fig. 1.2 — Bucle de interacción de alto nivel de la IA Agéntica




Fig. 1.2 — Bucle de interacción de alto nivel de la IA Agéntica

1.2 LLM Core: el motor de razonamiento y generación

- En el corazón de la mayoría de los sistemas agénticos hay un **Large Language Model (LLM)** u otro modelo fundacional
- Provee el razonamiento y la generación centrales: interpreta instrucciones, genera planes, coordina acciones
- Ej.: traduce la solicitud de un usuario en subtareas, o explica su propio razonamiento
- Se convierte en un "**augmented LLM**": formula sus propias consultas a una base de conocimiento
- Elige herramientas externas y decide qué información recordar

1.2 Reasoning and Planning: descompone objetivos en pasos ordenados

- **Chain-of-thought reasoning:** descompone un objetivo complejo en subtarefas ordenadas
- Ej.: un agente de codificación diseña, escribe módulos, los prueba y despliega el software automáticamente
- Los LLMs pueden generar planes de múltiples pasos para proyectos de ingeniería o procesos de negocio
- Estas capacidades a menudo **emergen solo en modelos a gran escala** (capacidades emergentes)
- Ciclo **plan** → **act** → **observe**: el LLM traza las próximas acciones, las ejecuta y retroalimenta los resultados al contexto
- **ReAct** (Yao et al., 2023): paper fundacional (ICLR 2023) que formaliza este entrelazado de razonamiento y acción — intercala *reasoning traces* con acciones ejecutables, permitiendo que el modelo planifique, maneje excepciones y consulte fuentes externas en el mismo flujo

1.2 Memory and Context: retiene conocimiento entre pasos

- Mecanismos de memoria para manejar tareas más largas en el tiempo
- Memoria de largo plazo (preferencias del usuario, hechos) o memoria de trabajo efímera para la sesión actual
- **Devin** (Cognition AI, 2024): recuerda el contexto de código relevante y *"aprende con el tiempo leyendo codebases, tests y documentos"*
- Frameworks usan **retrieval-augmented generation**: vector stores o bases de datos para fundamentar el razonamiento
- Dataiku (2024): los sistemas agénticos requieren *"arquitecturas de memoria persistente"* para metas y contextos que evolucionan


1.2 Tools and Actions: el agente decide qué herramienta invocar

- Rasgo definitorio de la IA Agéntica: el **uso de herramientas** — interfaces hacia APIs, CLI, navegadores web o hardware robótico
- Las herramientas tienen **esquemas** que definen qué hacen, para que el agente decida cuándo y cómo usarlas
- Ej.: búsqueda web para recolectar datos → API de base de datos para almacenar resultados → editor de código
- **Devin** (Cognition AI): shell integrada, editor de código y navegador en sandbox — *"todo lo que necesita para trabajar"*
- El módulo de acción invoca las herramientas en secuencia o colabora con otros agentes en un flujo complejo

1.2 Interaction Loop and Control Logic: la política que dirige el comportamiento

- Bucle de orquestación: lee el entorno (usuario o sensores), actualiza su memoria, razona con el LLM y emite acciones vía herramientas/APIs
- Incluye **verificación de errores** y **puntos de control humano-en-el-loop** (para seguridad o aprobación)
- Incorpora estrategias de respaldo (*fallback*) ante fallas
- Maneja lógica de ramificación (si una acción falla, intentar otra) y bucles (repetir hasta lograr éxito)
- Contempla la posible cooperación entre múltiples agentes

Fig. — Anatomía de un agente: 5 componentes en bucle



1.2 Síntesis: LLM aumentado + memoria + herramientas = autonomía

- Un agente se construye a partir de un **backbone de LLM aumentado** con razonamiento y planificación
- Se enriquece con memoria y se integra con interfaces de acción (herramientas)
- Observa entradas, genera planes (a menudo como cadenas de razonamiento), los ejecuta vía herramientas y aprende de los resultados
- Este bucle de extremo a extremo distingue a la IA Agéntica de aplicaciones de IA más simples, habilitando un comportamiento autónomo sofisticado

1.3 Tres niveles de autonomía: tradicional, generativa, agéntica

- La IA Agéntica difiere fundamentalmente tanto de la IA tradicional como de los modelos de IA generativa
- La Fig. 1.3, en la próxima slide, ilustra los tres tipos de IA desde la perspectiva del **grado de autonomía**
- Taxonomía más detallada: agentes **reactivos, deliberativos, híbridos y cognitivos**, entre otros (Huang, 2025a)
- Esta distinción es fundacional para el campo

Fig. 1.3 — Tres tipos de IA: de predicciones a contenidos a acciones




Fig. 1.3 — Tres tipos de IA: de predicciones a contenidos a acciones

1.3 Tabla 1.1 — Comparación de enfoques de IA

Aspect	Traditional AI	Generative AI	IA Agéntica
Core function	Classify or predict data (e.g., image recognition, fraud detection)	Generate new content (text, images, code) from prompts	Autonomously plan and execute multi-step tasks to achieve goals
User input	Often requires explicit examples or features; human designs rules or loss function	Requires a prompt or context from the user each time	Receives high-level goals or tasks; no prompt needed each step
Autonomy level	Low—Runs fixed model or rules on given data	Low to moderate—Creates output but waits for next prompt	High—Continuously acts with minimal intervention
Adaptivity	Static model after training; does not change unless retrained	Reactive—Adapts output only to input prompt; no online learning	Dynamic—Learns or adapts on the fly and can plan new actions if environment changes
Example applications	Handwritten digit recognition, spam filters, predictive maintenance (specific tasks)	Chatbots answering user queries, text/image synthesis, code generation	Autonomous vehicles, AI project engineers (e.g., coding agents), workflow automation platforms
Human oversight	Typically human-defined and supervised (human "in the loop" training)	Human provides prompts but not needed beyond that; humans oversee outputs	Humans set goals; agents operate "on their own," possibly with human on the loop monitoring

Tabla 1.1 — Comparación de enfoques de IA: tradicional, generativa y agéntica

1.3 IA Agéntica es "doer", no "responder"

- La IA Agéntica se distingue porque **actúa por su propia autoridad**
- IA tradicional y modelos generativos son *responders*: requieren una entrada específica y dan una salida
- Ej.: un clasificador de imágenes solo etiqueta; GPT escribe un ensayo si se le pide; **Devin** (Cognition) construye el proyecto de software completo por sí solo
- **IBM**: los sistemas agénticos se enfocan en **tomar decisiones**, no solo en generar contenido
- CMSWire (Palermo, 2025): los LLMs generativos no pueden planificar ni adaptarse a situaciones cambiantes — solo producen una respuesta a un prompt

1.4 Impulsores técnicos detrás del auge de la IA Agéntica

Avances en modelos, frameworks, integración física y herramientas de desarrollo convergen para habilitar sistemas autónomos más sofisticados.




Fig. 1.4 — Impulsores técnicos de la IA Agéntica

1.4 Driver 1 — El escalamiento de los modelos grandes habilita razonamiento emergente

- El crecimiento en cómputo y datos impulsó **habilidades emergentes** en los LLMs (GPT-4 y más allá)
- **Chain-of-thought prompting** (Wei et al., 2022): los modelos más grandes realizan lógica de múltiples pasos
- Los modelos detrás de Devin o Auto-GPT ya son suficientemente avanzados para descomponer tareas complejas
- Miehl et al. (2025): sumar "*capacidades de razonamiento y cierto grado de agencia*" abre el camino a sistemas más generales

1.4 Driver 2 — Los límites del SaaS monolítico empujan hacia agentes que conectan sistemas

- El SaaS tradicional ofrece flujos de trabajo e interfaces fijas; la IA Agéntica promete romperlas **uniendo herramientas entre sí**
- Los agentes pueden "*automatizar workflows*" y "*conectar sistemas dispares*" que las apps SaaS estáticas no pueden
- Ej.: un agente opera a través de múltiples plataformas (web, bases de datos, hojas de cálculo) por su cuenta
- "**Disrupción de software**": si una IA replica la lógica de negocio de un SaaS, el proveedor debe incorporar IA o especializarse
- Probablemente derive en ecosistemas híbridos, no en un reemplazo total del SaaS

1.4 Driver 3 — La integración física y robótica extiende la IA Agéntica al mundo real

- **"Physical AI"**: LLMs integrados con sistemas embebidos (*embodied*)
- **Gemini Robotics** (Google DeepMind): extiende Gemini 2.0 con una modalidad de salida de "acciones físicas" para controlar robots (DeepMind, 2025)
- **Magma** (Microsoft): interpreta interfaces de software y coordina movimientos robóticos en el mundo real
- Bousetouane (2024): los agentes de IA física combinan razonamiento LLM con control preciso de actuadores (cirugía, manufactura)
- Amplía el dominio de la IA Agéntica más allá del software puro

1.4 Driver 4 — Las plataformas no-code/low-code democratizan la construcción de agentes

- **ServiceNow Studio**: entorno unificado no-code, low-code y pro-code para aplicaciones agénticas
- **Copilot Studio** (Microsoft) y otras plataformas permiten diseñar visualmente flujos de trabajo de agentes
- Usuarios de negocio o equipos de seguridad prototipan arrastrando y soltando componentes, sin programar desde cero
- Budibase (2025): nuevos "**AI agent builders**" con autonomía y memoria preconstruidas
- Al reducir la barrera de entrada, el movimiento no-code expandió el mercado de soluciones agénticas

1.4 Driver 5 — Frameworks especializados aceleran el desarrollo

- Proliferación de frameworks para construir agentes: **LangChain**, **AWS Bedrock's Agent Framework**, **Vellum**, **Rivet**, **CrewAI**, entre otros
- Anthropic destaca **LangGraph** (LangChain) y el **AI Agent framework** de Amazon para "*simplificar tareas de bajo nivel*" como encadenar llamadas a LLMs
- Dataiku: frameworks open-source como **LlamaIndex** (con AgentKit), **AutoGen** y **CrewAI** ayudan a escalar agentes complejos y sistemas multi-agente
- Estos frameworks también guían implícitamente las mejores prácticas para arquitecturas de agentes

1.4 Síntesis: modelos, demanda de automatización, cuerpo físico y frameworks convergen

- Modelos cada vez más grandes habilitan nuevos comportamientos agénticos
- La demanda de automatización presiona a los sistemas estáticos
- Las capacidades físicas requieren inteligencia encarnada (*embodied*)
- Las herramientas y frameworks facilitan la construcción de agentes
- En conjunto, explican por qué la IA Agéntica se mueve rápidamente de los laboratorios hacia pilotos y productos empresariales

1.5 Los nuevos poderes de la IA Agéntica exigen seguridad especializada

- Los métodos convencionales de ciberseguridad —diseñados para software estático o procesos dirigidos por humanos— suelen ser inadecuados para agentes autónomos y adaptativos
- Cinco factores impulsan la necesidad de un enfoque de seguridad especializado en sistemas agénticos (próximas slides)

1.5 Factor 1 — Autonomía e impredecibilidad amplían la superficie de riesgo

- Un agente puede ejecutar una secuencia de acciones a través de sistemas sin supervisión humana inmediata
- Si se descontrola o es programado maliciosamente, puede atacar de forma más sigilosa que malware fijo (evadir firewalls, modificar controles de acceso)
- CyberArk (2025): *"agentes de IA no autorizados podrían operar sin control"* de maneras que las defensas no anticipan
- ActiveFence (2025): la autonomía e interconectividad de la IA Agéntica la vuelven blanco de ciberataques, fraude financiero y interrupciones operacionales
- Riesgos no teóricos: parte de un panorama de amenazas en evolución junto con la adopción de IA generativa en los negocios (Huang et al., 2024)
- Chan et al. (2023, FAccT): en la literatura académica, mayor **agencia algorítmica** (menor especificación de objetivos, impacto más directo, orientación a metas, planificación de largo plazo) se asocia sistemáticamente a daños más severos y de alcance sistémico — marco peer-reviewed independiente que respalda esta preocupación

1.5 Factor 2 — Falta de visibilidad y trazabilidad dificulta la auditoría

- La toma de decisiones dinámica hace más difícil rastrear el comportamiento de un agente
- Un agente puede generar subprocesos, acceder a datos y encadenar llamadas a APIs de maneras impredecibles
- ActiveFence: el aprendizaje y la adaptación dinámicos pueden "*oscurecer modificaciones de datos*", complicando las investigaciones forenses
- Cuando algo sale mal, es difícil reconstruir por qué el agente actuó así
- Esta opacidad limita la supervisión humana y complica el cumplimiento normativo

1.5 Factor 3 — Nuevas superficies de ataque: envenenamiento de memoria y de datos

- La combinación de software, modelos y hardware crea nuevas vulnerabilidades
- Un agente puede ser **envenenado** (*poisoned*): instrucciones o datos maliciosos inyectados en su memoria disparan comportamiento inseguro más adelante
- En aprendizaje activo, entradas adversarias distorsionan las acciones futuras del agente
- Ataques sobre la propia lógica de la IA: **reward hacking** en RL, manipulación de prompts
- **MAESTRO** (CSA) destaca *backdoor triggers* y *data poisoning* como amenazas propias de los agentes que aprenden (Huang, 2025)

1.5 Factor 4 — La escala de operación amplifica el impacto de un agente comprometido

- Los agentes operan de forma continua y a escala: un solo agente comprometido puede causar daño generalizado
- Ej.: un agente financiero que ejecuta *trades*, o un agente de control industrial que gestiona líneas de producción
- Una brecha en la autorización de un agente así podría causar daño financiero o físico severo antes de que los humanos lo noten
- ActiveFence: un agente secuestrado (*hijacked*) podría manipular mercados o robar datos
- Incluso tareas agénticas de bajo nivel requieren seguridad de alta confianza (*high-assurance*)


1.5 Factor 5 — Los controles tradicionales (firmas, ACL estáticas) no alcanzan

- Detección de malware basada en firmas y controles de acceso estáticos son insuficientes frente a un agente que aprende y evoluciona
- Los sistemas agénticos pueden eludir reglas estáticas diseñando enfoques novedosos
- Al aprender, eventualmente podrían descubrir y explotar "vacíos legales" en políticas de alto nivel
- CSA: proteger la IA Agéntica exige combinar "*ciberseguridad tradicional, controles específicos de IA y monitoreo continuo*", de forma iterativa y multicapa
- Se deben complementar firewalls e IAM convencionales con monitoreo de modelos, auditoría del comportamiento del agente y threat modeling específico

1.5 MAESTRO: threat modeling multicapa para IA Agéntica

- La **Cloud Security Alliance** introdujo **MAESTRO** (*Multi-Agent Environment, Security, Threat, Risk, and Outcome*) para llenar este vacío
- Extiende los modelos de amenazas clásicos (como STRIDE) con consideraciones específicas de IA
- Exige defensas holísticas: controles sobre el modelo, sobre los datos y la memoria, sobre las herramientas invocables y sobre las interacciones con otros agentes
- El equipo de seguridad debe mapear cómo cada componente podría ser abusado (ej.: planificación comprometida, objetivos divergentes)
- Conclusión: autonomía persistente, uso complejo de herramientas y aprendizaje continuo exigen evaluación de riesgo consciente de IA, threat modeling (MAESTRO) y monitoreo en tiempo real

Fig. — MAESTRO: defensa holística en cuatro dominios



1.6 Conclusión: autonomía y orientación a objetivos definen a la IA Agéntica

- Este tema cubrió la definición, los componentes centrales, los drivers y los riesgos emergentes de la IA Agéntica
- A diferencia de la IA tradicional o puramente generativa, los agentes inician acciones sobre tareas complejas, encadenando razonamiento y herramientas externas
- Su ascenso está impulsado por modelos a gran escala, nuevas plataformas de desarrollo y presión hacia más automatización
- Su naturaleza dinámica e interconectada también crea desafíos de seguridad que las defensas convencionales no pueden abordar completamente

1.6 Próximos pasos: MAESTRO como marco de threat modeling multicapa

- El resto del material profundiza en **MAESTRO** — framework de threat modeling y seguridad multicapa para entornos de IA Agéntica
- MAESTRO (*Multi-Agent Environment, Security, Threat, Risk, and Outcome*) ofrece una manera estructurada de analizar arquitecturas de agentes y anticipar ataques en todas las capas
- La IA Agéntica representa tanto un salto en capacidad de IA como un llamado a nuevos paradigmas de seguridad
- Con agentes convirtiéndose en "compañeros de equipo digitales" en ingeniería, salud y otros campos, es imperativo entender cómo funcionan y cómo protegerse de sus riesgos novedosos

Referencias del tema (1/4)

ActiveFence. (2025, March 13). *Key security risks posed by Agentic AI and how to mitigate them.*

<https://www.activefence.com/key-security-risks-posed-by-agentic-ai-and-how-to-mitigate-them/>

Anthropic. (2024, December 19). *Building effective AI agents.* <https://www.anthropic.com/research/building-effective-agents>

Bousetouane, F. (2024). *Physical AI agents: Integrating cognitive intelligence with real-world action.*

<https://arxiv.org/abs/2501.08944>

Budibase. (2025, April 25). *6 low/no-code AI agent builders.* Budibase Blog. <https://budibase.com/blog/ai-agents/no-code-ai-agent-builders/>

Chan, A., Salganik, R., Markelius, A., Pang, C., Rajkumar, N., Krasheninnikov, D., Langosco, L., He, Z., Duan, Y., Carroll, M., Lin, M., Mayhew, A., Collins, K., Molamohammadi, M., Burden, J., Zhao, W., Rismanni, S., Voudouris, K., Bhatt, U., Weller, A., Krueger, D., & Maharaj, T. (2023). Harms from increasingly agentic algorithmic systems. In *Proceedings of the 2023 ACM Conference on Fairness, Accountability, and Transparency* (pp. 651–666). ACM.

<https://doi.org/10.1145/3593013.3594033>

Referencias del tema (2/4)

Cognition AI. (2024, March 12). *Introducing Devin, the first AI Software Engineer*.

<https://cognition.ai/blog/introducing-devin>

CyberArk. (2025, February 28). *The agentic AI revolution: 5 unexpected security challenges*. CyberArk Blog.

Dataiku. (2024, October 2). *A tour of popular open source frameworks for LLM-powered agents*. Dataiku Blog.

DeepMind. (2025, March 12). *Gemini Robotics brings AI into the physical world*. Google DeepMind Blog.

Huang, K. (2025, February 6). *Agentic AI threat modeling framework: MAESTRO*. Cloud Security Alliance Blog.

Referencias del tema (3/4)

Huang, K. (2025a). The genesis and evolution of AI agents. In K. Huang (Ed.), *Agentic AI: Theories and practices* (pp. 1–22). Springer.

Huang, K., & Huang, J. (2025). AI agent tools and frameworks. In K. Huang (Ed.), *Agentic AI: Theories and practices* (pp. 23–50). Springer.

Huang, K., Ponnappalli, J., Tantsura, J., & Shin, K. T. (2024). Navigating the GenAI security landscape. In K. Huang, Y. Wang, B. Goertzel, Y. Li, S. Wright, & J. Ponnappalli (Eds.), *Generative AI security: Theories and practices* (pp. 31–58). Springer.

IBM. (2025). *What is agentic AI?* IBM Think.

Miehling, E., Ramamurthy, K. N., Varshney, K. R., Riemer, M., Bouneffouf, D., Richards, J. T., Dhurandhar, A., Daly, E. M., Hind, M., Sattigeri, P., Wei, D., Rawat, A., Gajcin, J., & Geyer, W. (2025). *Agentic AI needs a systems theory*. arXiv preprint arXiv:2503.00237.

Referencias del tema (4/4)

Palermo, F. (2025, February 14). *Will Agentic AI mean the end of SaaS?* CMSWire.

Wei, J., Wang, X., Schuurmans, D., Bosma, M., Ichter, B., Xia, F., Chi, E., Le, Q., & Zhou, D. (2022). *Chain-of-thought prompting elicits reasoning in large language models*. arXiv preprint arXiv:2201.11903.

Xi, Z., Chen, W., Guo, X., He, W., Ding, Y., Hong, B., Zhang, M., Wang, J., Jin, S., Zhou, E., Zheng, R., Fan, X., Wang, X., Xiong, L., Zhou, Y., Wang, W., Jiang, C., Zou, Y., Liu, X., Yin, Z., Dou, S., Weng, R., Cheng, W., Zhang, Q., Qin, W., Zheng, Y., Qiu, X., Huang, X., & Gui, T. (2025). The rise and potential of large language model based agents: A survey. *Science China Information Sciences*, 68(2), 121101. <https://doi.org/10.1007/s11432-024-4222-0>

Yao, S., Zhao, J., Yu, D., Du, N., Shafran, I., Narasimhan, K., & Cao, Y. (2023). ReAct: Synergizing reasoning and acting in language models. In *Proceedings of the 11th International Conference on Learning Representations (ICLR 2023)*. arXiv preprint arXiv:2210.03629.